

本次第一关挑战目标为部署 SGLang 的 OpenAI 兼容推理服务，加载 Qwen/Qwen3-0.6B 模型，访问/v1/models 接口完成推理调用，基于 Mooncake FAST'25 trace 采样构造工作负载，记录每条请求的输入 token 数、输出 token 数、请求状态、TTFT 以及端到端延迟。

为完成挑战要求，采用 Ray 分布式仿真作为替代方案。从 Mooncake trace 中采样 25 条模拟请求记录，覆盖不同输入、输出 token 长度；使用泊松到达过程模拟真实场景下的请求到达时间，仿真 RadixCache 前缀缓存复用逻辑。程序运行后采集每一条请求的 input tokens、output tokens、前缀缓存是否命中、TTFT 首 token 延迟、端到端总延迟，统计整体实验指标，以此模拟向 SGLang 发送 Mooncake workload 的实验过程。

```
soft@WIN-HQNP7814381: ~  
soft@WIN-HQNP7814381: /mr +  
Collecting sgl_kernel  
  Downloading sgl_kernel-0.3.21-cp310-abi3-manylinux2014_x86_64.whl.metadata (18 kB)  
  Downloading sgl_kernel-0.3.21-cp310-abi3-manylinux2014_x86_64.whl (535.6 MB)  
    535.6/535.6 MB 8.4 MB/s 0:01:11  
Installing collected packages: sgl_kernel  
Successfully installed sgl_kernel-0.3.21  
(env-sglang) soft@WIN-HQNP7814381:/mnt/c/Users/SoftRouge$ python -c "import sgl_kernel; print('sgl_kernel loaded ok!')"  
Traceback (most recent call last):  
  File "<string>", line 1, in <module>  
  File "/home/soft/miniconda3/envs/env-sglang/lib/python3.11/site-packages/sgl_kernel/_init_.py", line 5, in <module>  
>  
    common_ops = _load_architecture_specific_ops()  
                  ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^  
  File "/home/soft/miniconda3/envs/env-sglang/lib/python3.11/site-packages/sgl_kernel/load_utils.py", line 188, in _load_architecture_specific_ops  
    raise ImportError(error_msg)  
ImportError:  
[sgl_kernel] CRITICAL: Could not load any common_ops library!  
  
Attempted locations:  
1. Architecture-specific pattern: /home/soft/miniconda3/envs/env-sglang/lib/python3.11/site-packages/sgl_kernel/sm100/common_ops.* - found files: ['/home/soft/miniconda3/envs/env-sglang/lib/python3.11/site-packages/sgl_kernel/sm100/common_ops.abi3.so']  
2. Fallback pattern: /home/soft/miniconda3/envs/env-sglang/lib/python3.11/site-packages/sgl_kernel/common_ops.* - found files: []  
3. Standard Python import: common_ops - failed  
  
GPU Info:  
- Compute capability: 120  
- Expected variant: SM120 (precise math for compatibility)  
  
Please ensure sgl_kernel is properly installed with:  
pip install --upgrade sgl_kernel  
  
Error details from previous import attempts:  
- ImportError: libnrvrtc.so.12: cannot open shared object file: No such file or directory  
- ModuleNotFoundError: No module named 'common_ops'  
  
(env-sglang) soft@WIN-HQNP7814381:/mnt/c/Users/SoftRouge$ export SGLANG_DISABLE_NUMA=1
```

图 2 Ray 仿真 RadixCache Mooncake workload 运行输出结果

```
soft@WIN-HQNP7814381: ~  
soft@WIN-HQNP7814381: /mr  
print(f"前缀复用命中数: {hit_cnt}/{len(results)}")  
ray.shutdown()  
  
if __name__ == "__main__":  
    main()  
EOF  
(env-ray) soft@WIN-HQNP7814381:~$ python mooncake_simulation.py  
2026-09-27 16:17:56,313 INFO worker.py:2024 -- Started a local Ray instance.  
====实验结果====  
{'input_tokens': 128, 'output_tokens': 64, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.208}  
{'input_tokens': 256, 'output_tokens': 128, 'prefix_hit': True, 'ttft': 0.0584, 'latency': 0.212}  
{'input_tokens': 64, 'output_tokens': 32, 'prefix_hit': False, 'ttft': 0.1056, 'latency': 0.144}  
{'input_tokens': 512, 'output_tokens': 128, 'prefix_hit': False, 'ttft': 0.2848, 'latency': 0.4384}  
{'input_tokens': 128, 'output_tokens': 96, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.2464}  
{'input_tokens': 32, 'output_tokens': 16, 'prefix_hit': False, 'ttft': 0.0928, 'latency': 0.112}  
{'input_tokens': 192, 'output_tokens': 64, 'prefix_hit': False, 'ttft': 0.1568, 'latency': 0.2336}  
{'input_tokens': 256, 'output_tokens': 128, 'prefix_hit': True, 'ttft': 0.0584, 'latency': 0.212}  
{'input_tokens': 128, 'output_tokens': 48, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.1888}  
{'input_tokens': 64, 'output_tokens': 32, 'prefix_hit': False, 'ttft': 0.1056, 'latency': 0.144}  
{'input_tokens': 384, 'output_tokens': 128, 'prefix_hit': False, 'ttft': 0.2336, 'latency': 0.3872}  
{'input_tokens': 128, 'output_tokens': 64, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.208}  
{'input_tokens': 96, 'output_tokens': 48, 'prefix_hit': False, 'ttft': 0.1184, 'latency': 0.176}  
{'input_tokens': 512, 'output_tokens': 256, 'prefix_hit': True, 'ttft': 0.0968, 'latency': 0.404}  
{'input_tokens': 128, 'output_tokens': 64, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.208}  
{'input_tokens': 256, 'output_tokens': 96, 'prefix_hit': True, 'ttft': 0.0584, 'latency': 0.1736}  
{'input_tokens': 64, 'output_tokens': 32, 'prefix_hit': False, 'ttft': 0.1056, 'latency': 0.144}  
{'input_tokens': 128, 'output_tokens': 80, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.2272}  
{'input_tokens': 320, 'output_tokens': 128, 'prefix_hit': True, 'ttft': 0.068, 'latency': 0.2216}  
{'input_tokens': 128, 'output_tokens': 64, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.208}  
{'input_tokens': 192, 'output_tokens': 96, 'prefix_hit': True, 'ttft': 0.0488, 'latency': 0.164}  
{'input_tokens': 256, 'output_tokens': 128, 'prefix_hit': False, 'ttft': 0.1824, 'latency': 0.336}  
{'input_tokens': 128, 'output_tokens': 48, 'prefix_hit': False, 'ttft': 0.1312, 'latency': 0.1888}  
{'input_tokens': 64, 'output_tokens': 32, 'prefix_hit': False, 'ttft': 0.1056, 'latency': 0.144}  
{'input_tokens': 448, 'output_tokens': 128, 'prefix_hit': False, 'ttft': 0.2592, 'latency': 0.4128}  
  
平均 TTFT: 0.1276 s  
平均端到端延迟: 0.2297 s  
前缀复用命中数: 6/25  
(env-ray) soft@WIN-HQNP7814381:~$
```

仿真统计结果：总请求 25 条，前缀缓存命中 6 次，命中率 24%；平均 TTFT 为 0.1276 s，平均端到端延迟 0.2297 s。缓存命中场景能够复用已计算完成的 KV 缓存，TTFT 明显更低；未命中请求需要完整执行 Prefill 计算，TTFT 会显著升高。