

SGLang 推理请求处理流程图

一次用户推理请求在 SGLang 在线推理框架中的完整处理流水线如下：

1. 用户 Client **请求**：客户端发送包含 prompt 文本的大模型生成请求；
2. Tokenizer **分词**模块：将原始输入文本做分词处理，转换为模型可识别的 token id 序列；
3. Scheduler / 请求**队列**：请求进入系统调度器与请求队列，完成请求排队、动态批处理，把多个请求合并送入 GPU 计算；
4. Prefill 阶段：对输入的 prompt 序列执行 **Prefill 前向计算**，计算输入 token 对应的 KV 缓存；
5. RadixCache /page-sized KV Cache 缓存管理层：执行缓存分配、回收，同时执行 Prefix Reuse 前缀复用逻辑。查找前缀树，如果存在公共前缀 KV 缓存，则直接复用，跳过对应部分 token 的 Prefill 计算；
6. Decode 迭代循环：进入**解码**阶段，循环逐个生成输出 token；
7. Sampling **采样**：对模型输出 logits 做采样，选出下一个 token；
8. Streaming **流式输出**：将生成的 token 以流的形式返回给客户端；
9. Metric **指标统计**：统计本次请求各项性能指标，包含 TTFT、端到端 latency、输入输出 token 数量等。

