

阅读文献笔记

1. RadixAttention (NeurIPS 2024, SGLang)

论文提出 RadixAttention 以及 RadixCache 缓存机制，针对大模型多请求场景下重复 prompt 前缀带来的重复计算与显存浪费问题。该机制在分页 KV 缓存的基础上引入 [Radix 前缀树结构](#)，实现跨请求的 Prefix Reuse 前缀复用。多条请求如果拥有相同的 prompt 前缀，就可以共享同一份 KV 缓存，避免重复执行 Prefill 阶段计算，降低 TTFT 首 token 延迟，同时减少 GPU 显存占用，提升在线推理服务的并发吞吐。论文同时给出完整系统实现，也就是 SGLang 推理引擎。

2. PagedAttention (SOSP 2023, vLLM)

PagedAttention 是 vLLM 推理引擎的核心技术。传统 KV 缓存需要分配连续显存，请求不断创建销毁会造成严重显存碎片，限制系统最大并发。PagedAttention 借鉴操作系统虚拟[内存分页思想](#)，把 KV 缓存切分为大小固定的缓存页面，页面在显存中不需要连续，可以动态分配、回收。该方案极大降低显存碎片化，显著提升批处理并发能力。但是 PagedAttention 只支持单请求内部的页面管理，不支持不同请求之间共享 KV 缓存。

3. Mooncake FAST' 25 Trace

Mooncake 是开源的大模型线上[真实流量 trace 数据集](#)，发布于 FAST' 25。数据集采集真实线上业务的用户请求，记录大量请求的输入 token 长度、输出 token 长度等信息，可以用来构造贴近真实业务的 workload，用于大模型推理系统的性能评测、缓存策略仿真实验。本次实验就是基于该 trace 采样请求，模拟真实线上请求负载。